


Alpha-Beta-Pruning

Carsten Gips (FH Bielefeld)

Unless otherwise noted, this work is licensed under CC BY-SA 4.0.

Verbesserung Minimax-Algorithmus



=> Minimax-Baum: Verbesserungen möglich?

Alpha-beta-Pruning

Minimax-Algorithmus mit zusätzlichen Informationen:

- α : bisher bester Wert für MAX (höchster Wert)
- β : bisher bester Wert für MIN (kleinster Wert)

Alpha-beta-Pruning

Minimax-Algorithmus mit zusätzlichen Informationen:

- α : bisher bester Wert für MAX (höchster Wert)
- β : bisher bester Wert für MIN (kleinster Wert)

=> Beobachtungen:

1. α für MAX-Knoten wird nie kleiner
2. β für MIN-Knoten wird nie größer

Tafelbeispiel: Beste Werte einzeichnen

Pruning-Regeln

1. Schneide (unter) MIN-Knoten ab, deren $\beta \leq$ dem α des MAX-Vorgängers ist.
2. Schneide (unter) MAX-Knoten ab, deren $\alpha \geq$ dem β des MIN-Vorgängers ist.

Abbruch, wenn kein Platz
mehr zwischen Alpha und Beta

Alpha-beta-Pruning – Der Algorithmus (Skizze)

```
def Max-Value(state, alpha, beta):  
    if Terminal-Test(state): return Utility(state)  
  
    v = -INF  
    for (a, s) in Successors(state):  
        v = MAX(v, Min-Value(s, alpha, beta))  
        if (v >= beta): return v  
        alpha = MAX(alpha, v)  
    return v
```

Initialer Aufruf von `Max-Value()` mit $\alpha = -\infty$ und $\beta = +\infty$

Alpha-beta-Pruning – Eigenschaften

1. Pruning beeinflusst nicht das Endergebnis!
2. Sortierung der Nachfolger spielt große Rolle
3. Perfekte Sortierung: $O(b^{d/2}) \Rightarrow$ Verdopplung der Suchtiefe möglich

Für Schach immer noch zu aufwändig ...

Verbesserungen für Alpha-beta-Pruning

- “Killer-Move”: Maximale Effizienz nur wenn **optimaler Zug immer zuerst**
=> Zu untersuchende Züge **sortieren/priorisieren**, zb. Schach:
 - a) Figuren schlagen
 - b) Drohen
 - c) Vorwärts ziehen
 - d) Rückwärts ziehen
- Verändern der Suchtiefe nach Spielsituation
- Bewertungsfunktion **Eval**:
 - Datenbanken mit Spielsituationen und Expertenbewertung:
 - Eröffnungsspiele (besonders viele Verzweigungen)
 - Endspiele
 - Lernen der optimalen Gewichte für **Eval**-Funktion
 - Berücksichtigung von Symmetrien

Beispiel DeepBlue (IBM, 1997)

- Alpha-beta-Pruning mit Tiefenbeschränkung: ca. 14 Halbzüge
- Dynamische Tiefenbeschränkung (stellungsabhängig, max. ca. 40 Züge)
- Heuristische Stellungsbewertung **Eval**:
 - mehr als 8.000 Features
 - ca. 4.000 Eröffnungsstellungen
 - ca. 700.000 Spielsituationen (von Experten bewertet)
 - Endspiel-Datenbank: alle Spiele mit 5 Steinen, viele mit 6 Steinen

Quelle: (Russell und Norvig 2014, p. 185)

Beispiel AlphaGo (Google, 2016)

- Beschränkung der Suchtiefe: Bewertung der Stellung durch *“Value Network”*
- Beschränkung der Verzweigungsbreite: Bestimmung von Zugkandidaten durch *“Policy Network”*
- Training dieser *“Deep Neural Networks”*:
 - Überwachtes Lernen: “Analyse” von Spiel-Datenbanken
 - Reinforcement-Lernen: Self-Play, Bewertung am Ende
 - Züge mit Monte-Carlo-Baumsuche ausgewählt

Quelle: (Silver u. a. 2016), siehe auch deepmind.com/research/alphago/

- Alpha-beta-Pruning:
 - Mitführen der bisher besten Werte für MAX und MIN: α und β
 - Abschneiden von Pfaden, die Verschlechterung bewirken würden
 - Endergebnis bleibt erhalten
 - Effizienzsteigerung abhängig von Sortierung der Nachfolger
- Viele Verbesserungen denkbar:
 - Zu untersuchende Züge “richtig” sortieren (Heuristik)
 - Suchtiefe begrenzen und Bewertungsfunktion (statt Nutzenfunktion)
 - Positionen mit Datenbank abgleichen

LICENSE



Unless otherwise noted, this work is licensed under CC BY-SA 4.0.