



• NICHTLINEARE MODELLE

- Wie können wir nichtlineare Beziehungen erfassen?

- Nichtlineare Regression




$$h(x) = \omega_0 + \omega_1 x_1 \quad \checkmark$$




$$h(x) = \omega_0 + \omega_1 x_1 + \omega_2 x_1^2$$

- Nichtlineare Klassifizierung



$$h(x) = \sigma(\omega_0 + \omega_1 x_1 + \omega_2 x_2) \quad \checkmark$$



$$h(x) = \sigma(\omega_0 + \omega_1 x_1 + \omega_2 x_2 + \omega_3 x_1^2 + \omega_4 x_2^2)$$

- IDEE: Kombiniere Merkmale x_1, x_2 auf nichtlineare Weise und führe neue Merkmale ein, e.g.

$$\underbrace{x_1^2}_{x_3}, \underbrace{x_1^3}_{x_4}, \underbrace{x_1^4}_{x_5}, \underbrace{x_2^2}_{x_6}, \underbrace{x_1 \cdot x_2}_{x_7}, \underbrace{x_1^2 x_2}_{x_8}, \dots$$


(Neue Merkmale!)

- Bemerkung: $w^T x$ ist weiterhin linear in w !

$$w^T x = w_0 + w_1 x_1 + w_2 x_1^2 + w_3 \cdot x_1^3 + w_4 \cdot x_1^4 + \dots$$

↗
 ↗
 Zahlen

BSP. Polynomiale Regression ($n=1$)




- $D = \{(1, 0.5), (2, 1.5), (3, 2), (4, 3), (5, 3), (6, 3), (7, 3.2), (8, 2.9), (9, 2) (10, 1)\}$
- Nichtlineare Beziehung zwischen x_1 und y
- Kein gutes $h(x) = w_0 + w_1 x_1$ möglich
→ Kosten gehen nicht herunter!
- Neues Merkmal $x_2 := x_1^2$ einführen : $x = (x_1, x_1^2) = (x_1, x_2)$
→ $x^{(1)} = (1, 1)$, $x^{(2)} = (2, 4)$, $x^{(3)} = (3, 9)$, ...
- Hypothesenfunktion : $h(x) = w_0 + w_1 x_1 + w_2 x_1^2$
→ $h(x) = -0.5 + 1.2 x_1 - 0.1 x_1^2$ besser
→ $h(x)$ lineare Funktion ins x_1 und x_2
(quadratisch in x_1)

BSP.

Polynomiale Klassifikation

(n=2)



- $X = \mathbb{R}^2$ $y = \{0, 1\}$
- Daten nicht linear separierbar.
- Keine gute lineare Hypothese

$$h(x) = \sigma(w_0 + w_1 x_1 + w_2 x_2)$$

- Durch die Einführung der neuen Merkmale $x_3 := x_1^2$ und $x_4 := x_2^2$ erhalten wir die neue Hypothesenfunktion:

$$h_w(x) = \sigma(w_0 + w_1 x_1 + w_2 x_2 + w_3 \cdot x_1^2 + w_4 \cdot x_2^2)$$

- Sei $w = (-4, 0, 0, 1, 1)$
- Entscheidungsgrenze : $w^T x = 0$

$$-4 + 0 \cdot x_1 + 0 \cdot x_2 + 1 \cdot x_1^2 + 1 \cdot x_2^2 = 0$$

$$\frac{x_1^2 + x_2^2 = 4}{\text{Entscheidungsgrenze}}$$




$$X = \begin{bmatrix} x_0 \\ x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ x_1 \\ x_2 \\ x_1^2 \\ x_2^2 \end{bmatrix}$$


(Kreis mit Radius 2.)

- $-4 + x_1^2 + x_2^2 < 0 \Rightarrow x_1^2 + x_2^2 < 4$
 \Rightarrow Das Innere des Kreises wird negativ klassifiziert.

• OVERFITTING (Überanpassung)

z.B. Polynom mit Grad 10

 Regression	 gute Anpassung "Right" Fit	 Überanpassung Overfit
<ul style="list-style-type: none"> Unteranpassung Underfit High Bias (unflexibel) Modell zu einfach 	<ul style="list-style-type: none"> gute Anpassung "Right" Fit (flexibel genug) 	<ul style="list-style-type: none"> Überanpassung Overfit High Variance (zu flexibel) Modell zu komplex

 Klassifikation		
<ul style="list-style-type: none"> $\sigma(\omega_0 + \omega_1 x_1 + \omega_2 x_2)$ (zu wenig Merkmale) 	<ul style="list-style-type: none"> $\sigma(\omega_0 + \omega_1 x_1 + \omega_2 x_2 + \omega_3 x_1^2 + \omega_4 x_2^2 + \omega_5 x_1 x_2)$ 	<ul style="list-style-type: none"> $\sigma(\omega_0 + \omega_1 x_1 + \omega_2 x_2 + \omega_3 x_1^2 + \omega_4 x_2^2 + \omega_5 x_1 x_2 + \omega_6 x_1^3 + \omega_7 x_1^2 x_2^2 + \dots)$ (zu viele Merkmale)

- Die Komplexität des Modells ist zu hoch; höher als es die Zielfunktion erfordert. Das Modell nutzt die extra "Freiheitsgrade", um sich den Eigenartigkeiten und "Noise" in den Daten anzupassen.

- "Was im Bereich des maschinellen Lernens professionelle von Amateuren unterscheidet, ist ihre Fähigkeit mit Überanpassung umzugehen." (Abu Mostafa, Learning from Data)

• Diagnose

- Sehr sehr gute Performanz auf Trainingsdaten
 \rightarrow Kosten $J(\theta) \approx 0$

Sehr schlechte Performanz auf neuen unbekannten Daten] !
 \rightarrow Schlechte Generalisierung / Vorhersagekraft] !

- Hypothesenfunktion lernt "gesehene" Daten auswendig, kann nicht gesehene Beispiele nicht gut vorhersagen.


• Maßnahmen

- Reduziere #Merkmale (reduziere Komplexität des Modells)
 \rightarrow Welche Merkmale weglassen?

- Regularisierung : behalte alle Merkmale
 reduziere Absolutwerte der Gewichte wj
 \rightarrow führt zu einfacheren Modellen.

• Regularisierung - Intuition


$$\circ h(x) = \omega^T x = \omega_0 + \omega_1 x + \omega_2 x^2 + \omega_3 x^3 + \omega_4 x^4 + \omega_5 x^5 + \omega_6 x^6$$



Overfit

- Lasse die Merkmale x^3, x^4, x^5, x^6 weg ($\omega_3 = \omega_4 = \omega_5 = \omega_6 = 0$)
(Terme höherer Ordnung weggelassen)

$$h(x) = \omega^T x = \omega_0 + \omega_1 x + \omega_2 x^2$$



Right Fit

- Reduziere Absolutwerte von $\omega_1, \omega_2, \omega_3, \omega_4, \omega_5$ und ω_6 mit Hilfe der Kostenfunktion:

$$\min_w \frac{1}{2m} \left[\sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + 1000 \cdot (\omega_1^2 + \omega_2^2 + \dots + \omega_6^2) \right]$$

$= 0 \quad = 0 \quad \approx 0$

- Regularisierte Lineare Regression

Regularisierungsparameter

Kostenfunktion

$$J(\omega) = \frac{1}{2m} \left[\sum_{i=1}^m (h(x^{(i)}) - y^{(i)})^2 + \lambda \cdot \sum_{j=1}^n \omega_j^2 \right]$$

ω_0 nicht regularisieren!

- Regularisierte Logistische Regression

Kostenfunktion

$$J(\omega) = \frac{1}{m} \left[\sum_{i=1}^m \left(-y^{(i)} \cdot \log(h(x^{(i)})) - (1-y^{(i)}) \cdot \log(1-h(x^{(i)})) \right) + \frac{\lambda}{2} \cdot \sum_{j=1}^n \omega_j^2 \right]$$

$$\frac{\partial}{\partial \omega_j} \left(\frac{\lambda}{2} (\omega_1^2 + \omega_2^2 + \dots + \omega_j^2 + \dots + \omega_n^2) \right) = \frac{\lambda}{2} \cdot 2\omega_j = \lambda \cdot \omega_j$$

- Gewichtsaktualisierung (für $j \geq 1$)

$$\omega_j := \omega_j - \frac{\alpha}{m} \cdot \left[\sum_{i=1}^m ((h(x^{(i)}) - y^{(i)}) \cdot x_j^{(i)}) + \lambda \cdot \omega_j \right]$$